I Seminarium Python Geodata Science

Hel 18-22 marzec 2019





GISCO: GEOGRAPHICAL INFORMATION AND MAPS

Overview

- **▼**GEODATA
- ▼GISCO activities

Frequently asked questions (FAQ)

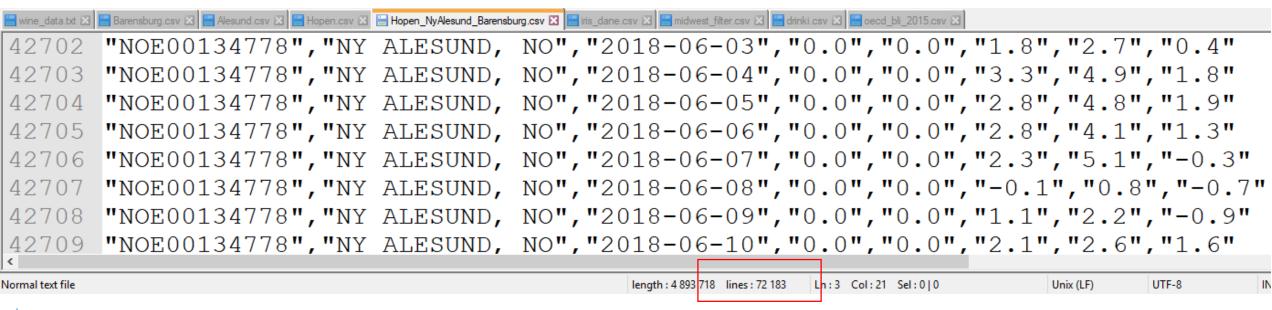
GEODATA

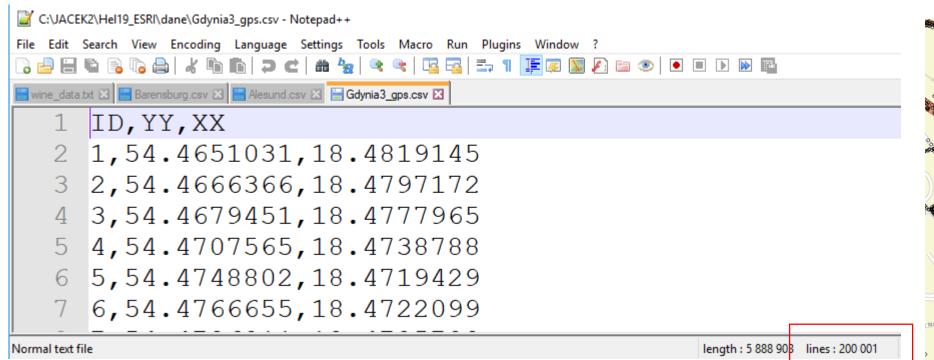
General information on geo-datafiles

All datasets are provided with their metadata in XML format. Geographic information system (GIS) software is needed to process the downloaded geodata.

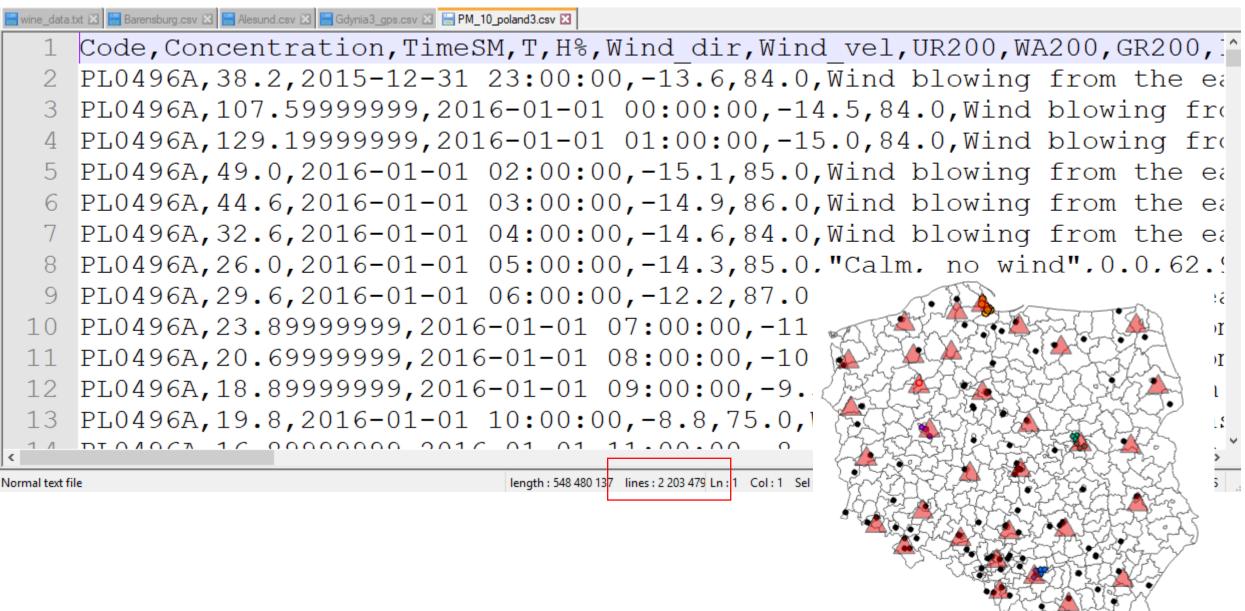
Geographical datasets are provided in two formats: Shapefile and 'Personal File Geodatabase'.

Shapefiles have a limitation in the attribute name length. For this reason, the attribute name might be truncated when compared with the name in the metadata or in the personal file geodatabase.





SKNIE THE STATE OF THE STATE OF









Zdjęcia satelitarne

DATA **SCIENCE**

DATA ENGINEERING

COMPUTATIONAL DATA SCIENCE

POZYSKIWANIE

PRZYGOTOWANIE

ANALIZA

RAPORTOWANIE

DZIAŁANIE

PLIKI TEKSTOWE BAZY DANYCH Web serwisy No SQL storage

Eksploracja EDA

PREPROCESSING

Korelacja

Trend

Outliers

Statystyki

Wizualizacja

Czyszczenie Transformacja

Duplicate

Inconsistent

Missing

Outlier

Scailing

Transformation

Feature selection

Dimensions PCA

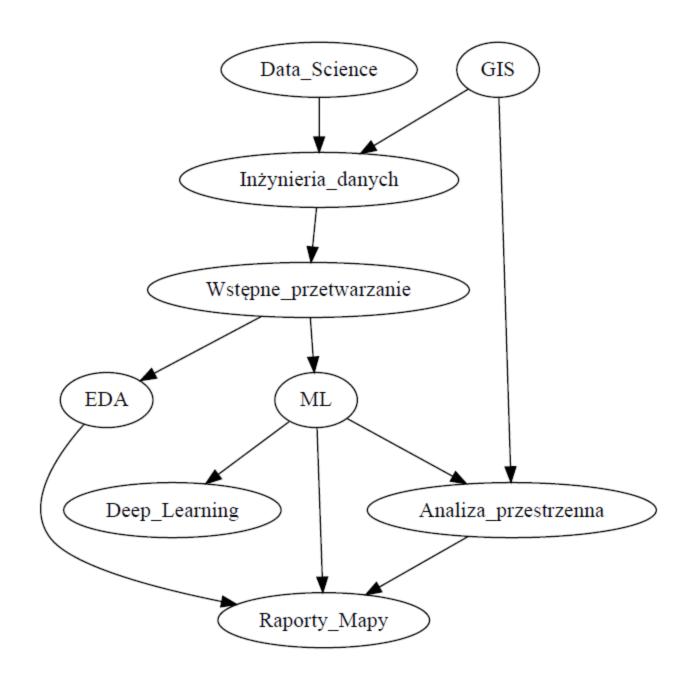
Classification

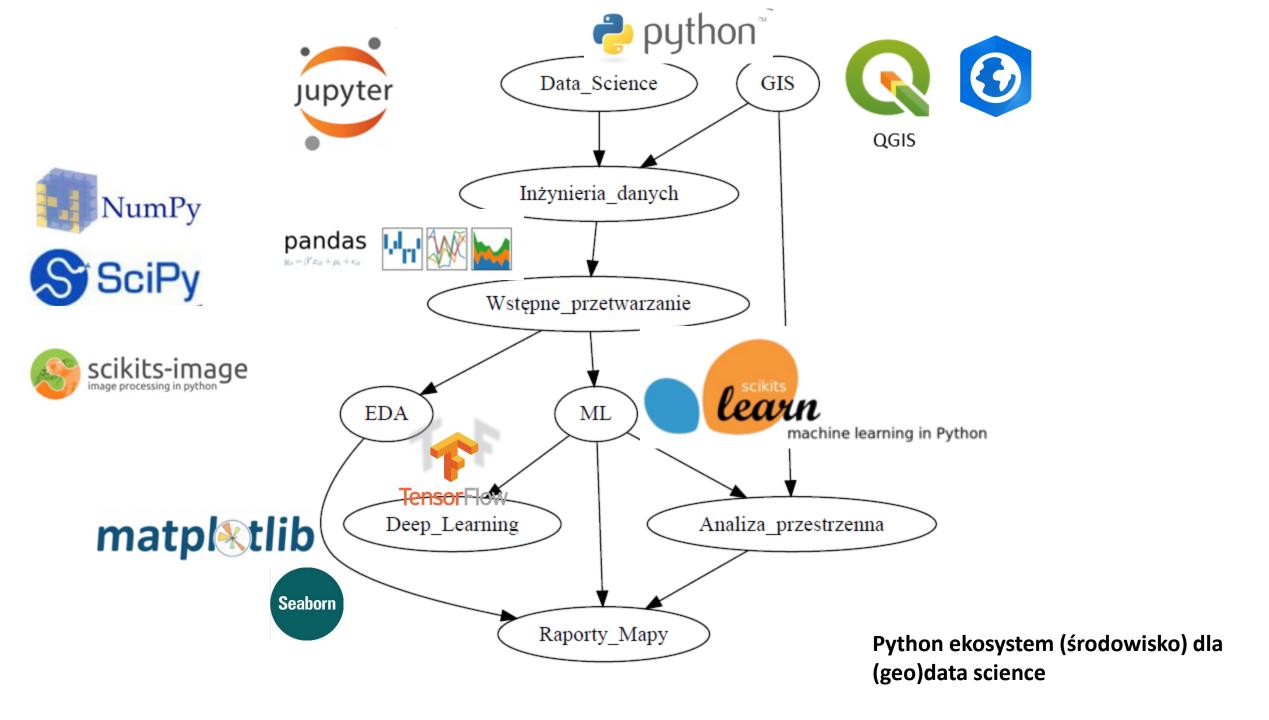
Regression

Clustering

Graph Analytics

Histogramy **Boxplots** Line graph

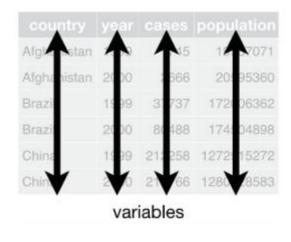


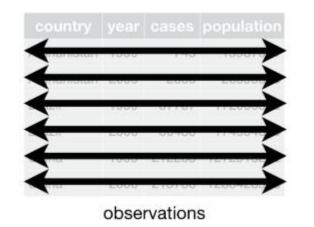


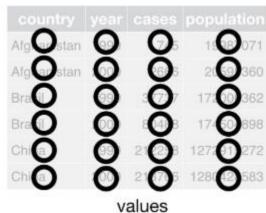
Struktura danych - Tidy data (uprządkowane dane)

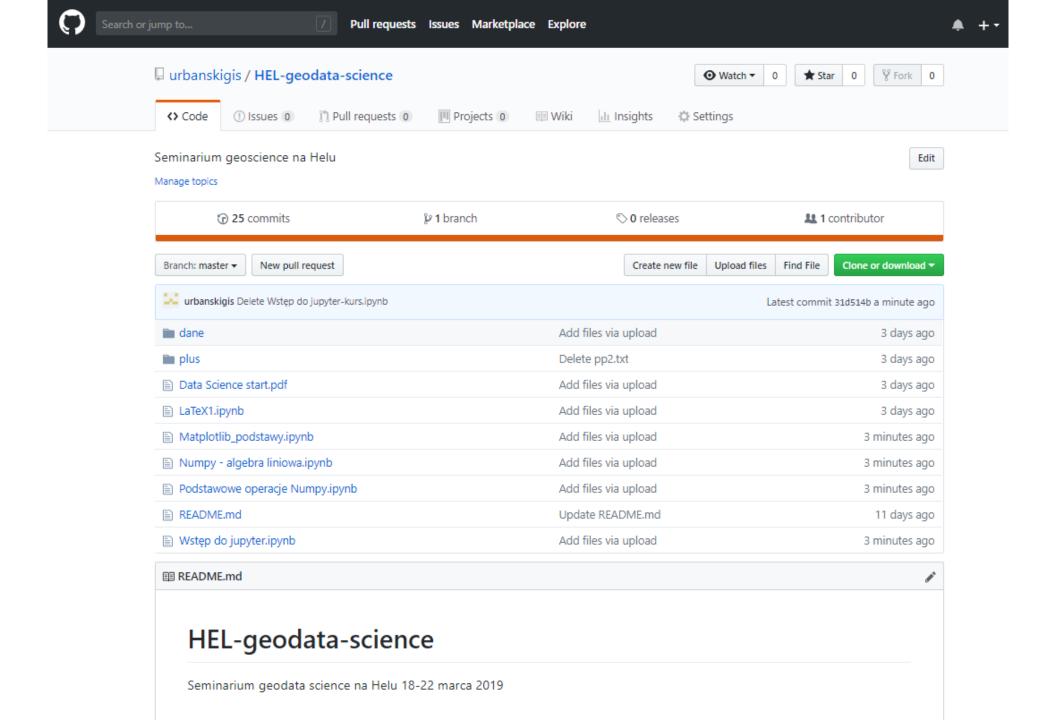
Tidy data dane otrzymane w rezultacie procesu nazywanego data tidying. Jest to pierwszy podstawowwy krok poprzedzający **data cleaning** i jest istotnym krokiem w praktyce **data science**. Takie (tidy) zbiory danych mają określoną strukturę dzięki której praca z nimi jest prosta, są proste do przetwarzania, modelowania i wizualizacji. Dzięki temu można do nich stosować wiele generycznych algorytmów pozwalających na ich przetwarzanie. Tidy **data sets** są zorganizowane w taki sposób, że zmienne (variable, atrybuty, features) tworzą kolumny a każda obserwacja (observation, *case, wektor*) jest rzędem. Tidy data tworzą standardy i koncepcje do **data cleaning**, pozwala to na wykorzystanie standardowych metod czyszczenia danych.

- Każda zmienna mierzona powinna tworzyć jedną kolumnę.
- 2. Każda jej obserwacja powinna być w innym rzędzie.
- Powinna być jedna tablica dla każdego rodzaju zmiennych.
- 4. Jeżeli jest wiele tablic, powinny zawierać kolumnę, która pozwoli na ich łączenie.









https://towardsdatascience.com/
https://dataelixir.com/newsletters/

https://statquest.org/video-index/