

# Analiza obrazu

- wykorzystanie możliwości oferowanych w ramach pakietu scikit-image

Marta Konik

Pracownia Teledetekcji  
Instytut Oceanologii PAN

# Kilka słów o scikit-image

Autorem tej biblioteki jest **Stéfan van der Walt**. Nazwa “SciKit” ma odnosić się do “SciPy Toolkit”, choć jest rozpowszechniana niezależnie. Jest napisana w dwóch częściach w języku programowania python, jednak warto zauważyć, że niektóre elementy zostały napisane w języku Cython w celu zwiększenia efektywności obliczeniowej. Pakiet jest dostępny niezależnie od systemu operacyjnego komputera, więc mogą z niego korzystać zarówno użytkownicy Windows, jak i GNU/Linux lub Mac OS X.

Scikit-image jest oparty na bibliotekach NumPy i SciPy. Umożliwia zaawansowaną analizę graficzną, manipulację kolorami, różnego rodzaju przekształcenia geometrii obrazu, filtrację, segmentację, wbudowaną detekcję obiektów oraz wiele więcej.



<https://bids.berkeley.edu>

# Kilka słów o scikit-image

Od wersji 0.10 scikit image składa się z następujących modułów:

- color – manipulacja kolorami
- data - przykładowe obrazy testowe
- draw - podstawowe funkcje rysowania oparte o NumPy
- exposure – funkcje dopasowania kontrastu
- feature - identyfikacja obiektów (m.in. analizy tekstury)
- filter - filtracja
- graph – tworzenie grafów (na podst. teorii grafów)
- io – czytanie, zapisywanie i kompatybilność z innymi bibliotekami
- measure – statystyki obiektów
- morphology – operacje morfologiczne
- novice – wsparcie dla edukatorów i nauczycieli
- restoration – algorytmy odtwarzania sygnałów
- segmentation - segmentacja
- transform – transformacje geometryczne
- viewer – specjalny moduł do wizualizacji


# Możliwości scikit-image




(a) Petra images



(d) Warped & positioned



(b) ORB binary features




(c) RANSAC-filtered features



(e) Final result, combined with Enblend

# Możliwości scikit-image



Fotografia płytki krzemowej



Bioluminescencja domieszek



Zidentyfikowane domieszki



Van derWalt et al. (2014)

<https://github.com/vessemer/LungCancerDetection>

# DATA SCIENCE a analiza obrazu

## DATA SCIENCE

### DATA ENGINEERING

### COMPUTATIONAL DATA SCIENCE

POZYSKIWANIE

PRZYGOTOWANIE

ANALIZA

RAPORTOWANIE

DZIAŁANIE

PLIKI TEKSTOWE

BAZY DANYCH

Web serwisy

No SQL storage

Eksploracja EDA

Korelacja  
Trend  
Outliers  
Statystyki

Wizualizacja

Histogramy  
Boxplots  
Line graph

PREPROCESSING

Czyszczenie Transformacja

Duplicate  
Inconsistent  
Missing  
Outlier  
Scailing  
Transformation  
Feature selection  
Dimensions PCA

Classification

Regression

Clustering


Graph Analytics

.....



# Poruszane tematy

- Odpowiednia wizualizacja
- Transformacja geometryczna
- Usunięcie szumów
- Czasem wyostrzenie granic obiektów
- Opisanie tekstury
- Identyfikacja obiektów poprzez segmentację
- Charakterystyka otrzymanych obiektów
- ...
- Klasyfikacja



# Dopasowanie kontrastu


*Jest to **sposób przypisania wartości intensywności koloru** do wartości rastra. Jeśli obraz jest **kolorowy**, wartości **przypisuje się osobno** każdej z trzech składowych: czerwonej, zielonej i niebieskiej, (RGB red-green-blue).*

True colour



8.01.2019 MSI, Sentinel-2, ESA

False colour

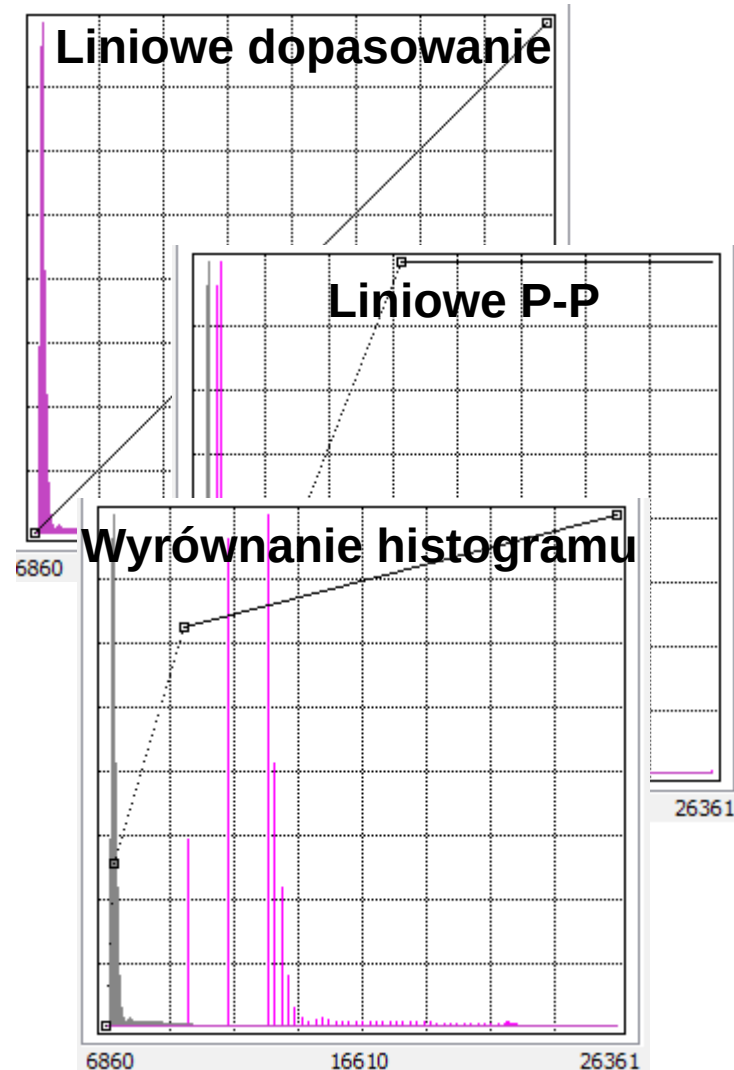


8.01.2019 MSI, Sentinel-2, ESA





# Metody dopasowywania kontrastu

- Liniowy – funkcją liniową dopasowuje się wartości w określonym zakresie
  - min – max
  - pomiędzy określonymi percentylami naszego zbioru wartości rastra
- Nieliniowy
  - dopasowanie krzywą gaussa
  - dopasowanie krzywą logarytmiczną
- Wyrównanie histogramu – funkcja, która przypisuje wartości tak, aby histogram obrazu przekształceniu był możliwie płaski. Polecany przy dużym zróżnicowaniu wartości i niesymetrycznym histogramie obrazu początkowego




# Transformacje geometryczne



- Przesunięcie
- Obrót
- Zmiana rozdzielczości przestrzennej
- Zmiana rozdzielczości radiometrycznej, czyli typu zapisu wartości (przejście float – int)


# Progowanie obrazu



Rastry binarne, czyli takie, które składają się jedynie z wartości 0 i 1 tworzy się różnymi metodami klasyfikacji

# Przekształcenia kontekstowe

W tego rodzaju przekształceniach **każdemu pikselowi przypisywana jest wartość na podstawie wartości pikseli z sąsiedztwa**. Jego wielkość oraz sposób przekształcenia definiuje tzw. maska lub okno. Zwykle definiowane są maski kwadratowe o nieparzystym rozmiarze. Warto zwrócić uwagę na przekształcenie wartości przy krawędziach obrazu.



# Filtry morfologiczne

Opening filter

1	0	0	0	1
1	1	0	1	1
1	1	1	1	1
1	1	0	1	1
1	0	0	0	1

0	0	0	0	0
1	1	0	1	1
1	1	0	1	1
1	1	0	1	1
0	0	0	0	0

Filtr typu *opening* usuwa drobne jasne obiekty (1) i łączy ze sobą ciemne obszary zaznaczone wartością 0. W wyniku otrzymujemy obszary o większej ciągłości przy wzroście powierzchni klasy 0.  
→ Usunięcie małych obiektów (1)

Closing filter

0	0	0	0	0
0	0	0	0	0
1	1	0	1	1
0	0	0	0	0
0	0	0	0	0

0	0	0	0	0
0	0	0	0	0
1	1	1	1	1
0	0	0	0	0
0	0	0	0	0

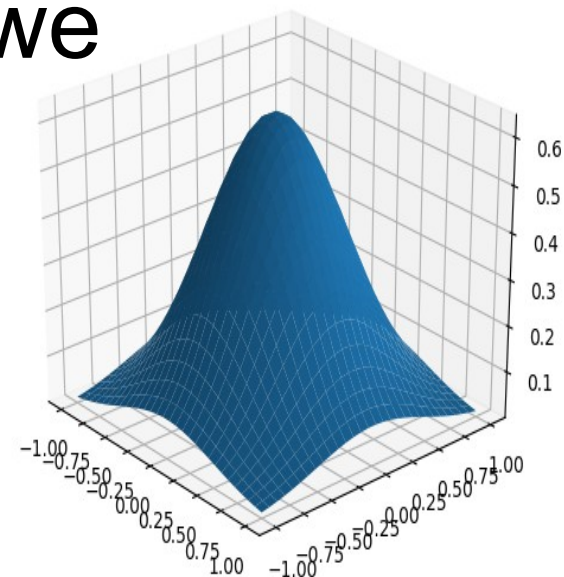
Filtr typu *closing* usuwa uzupełnia jasne obszary zaznaczone wartością 1. W wyniku otrzymujemy obszary o większej ciągłości przy wzroście powierzchni klasy 1.  
→ Wypełnienie małych dziur (0)



# Filtry wygładzające

## - dolnoprzepustowe

*Często na obrazie widać duże różnice między sąsiednimi pikselami, tzw. ziarnistość lub efekt “soli i pieprzu”. Redukcja tego efektu niesie ze sobą ryzyko “rozmycia” granic obiektów*



Przykładowa maska filtru gauss`a przy  $\sigma = 1$

0.5	1	0.5
1	15	1
0.5	1	0.5

# Filtry podkreślające granice

## - górnoprzepustowe

*Filtry górnoprzepustowe są oparte na obliczeniu pierwszej lub drugiej pochodnej. Bardzo wrażliwe na szumy i wartości odstające*

Powszechne filtry górnoprzepustowe:

- Laplace'a
- Sobel'a
- Roberts'a

Roberts kernel

-1	0	1	0
0	1	0	-1

Laplace kernel

0	-1	0	-1	-1	-1
-1	4	-1	-1	8	-1
0	-1	0	-1	-1	-1

Sobel kernel


-1	0	1	-1	-2	-1
-2	0	2	0	0	0
-1	0	1	1	2	1

# Przekształcenia całego obrazu

- Filtracja falkowa (wavelet) – wykorzystanie transformaty falkowej do usunięcia szumów
- TV Chambolle, czyli iteracyjne dopasowanie funkcji, która da wynik o mniejszej wariancji wartości, ale zapewni jak najmniejszą sumę kwadratów błędów:

$$E(x, y) = \frac{1}{n} \sum_n (x_n - y_n)^2$$

- Filtr bilateralny (bilateral) – usuwa wartości odstające, porównując wartości rastra pod kątem ich wzajemnej odległości przestrzennej oraz podobieństwa wartości, na podstawie odległości Euklidesowej i zdefiniowanego odchylenia standardowego.



# Porównywanie obrazów

- Wybrane indeksy służące do porównywania ze sobą obrazów:
- MSE, Mean Square Error - średni błąd kwadratowy
- Peak signal-to-noise ratio – szczytowy stosunek sygnału do szumu
- SSIM, Structural Similarity Indeks

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + c_1)(2\sigma_{xy} + c_2)}{(\mu_x^2 + \mu_y^2 + c_1)(\sigma_x^2 + \sigma_y^2 + c_2)}$$

$x, y$  – warstwy porównane o rozmiarze  $N \times N$

$\mu$  – średnia wartości

$\sigma$  – odchylenie standardowe

$\sigma_{xy}$  – kowariancja pomiędzy  $x, y$

$c_1, c_2$  – współczynniki, gdzie  $c_1 = (k_1L)^2$ ,  $c_2 = (k_2L)^2$ ,  $k_1=0.01$ ,  $k_2=0.03$ ,  $L$  – zakres radiometryczny

$$MSE = \frac{1}{N \cdot M} \sum_{i=1}^N \sum_{j=1}^M ([f(i, j) - f'(i, j)]^2)$$

- wymiary obrazu [px]
- współrzędne piksela obrazu referencyjnego
- współrzędne piksela obrazu porównywanego

$$PSNR = 10 \cdot \log_{10} \left( \frac{[\max(f(i, j))]^2}{MSE} \right)$$

- maksymalna wartość sygnału

# Miary opisujące teksturę

*Tekstura - opis zależności przestrzennych pomiędzy pikselami na obrazie*



Metoda GLCM – za pomocą macierzy opisującej współwystępowanie wartości w zależności od odległości między nimi (z ang. “co-occurrence matrix”)

$i$  – numer wiersza obrazu  $N \times N$

$j$  – numer kolumny

$P(i,j)$  – wartość piksela w punkcie  $i,j$

Miary wyznaczone metodą GLCM:

- $Korelacja = \sum_{i,j=0}^{N-1} P_{i,j} \left\{ \frac{(i - \mu_i)(j - \mu_j)}{\sqrt{(\sigma_i^2)(\sigma_j^2)}} \right\}$
- $Homogeniczność = \sum_{i,j=0}^{N-1} \frac{P_{i,j}}{1 + (i - j)^2}$
- $Kontrast = \sum_{i,j=0}^{N-1} P_{i,j} (i - j)^2$
- $Odmienność$   
(*Dissimilarity*)  $= \sum_{i,j=0}^{N-1} P_{i,j} |i - j|$
- $Energia = \sqrt{\sum_{i,j=0}^{N-1} P_{i,j}^2}$




# Sposoby segmentacji obrazu

Wybrane metody segmentacji

- **Felzenszwalb** – na podstawie zmienności w sąsiedztwie różnych wielkości **organizuje dane w postaci grafów**, na podstawie których dzieli obraz na podobszary [Felzenszwalb i Huttenlocher, 2004]
- **Quickshift** – oparta na algorytmie mean-shift, czyli analizy wartości wewnątrz pewnego **okna, które jest przesuwane tak długo w kierunku swojego “środku masy”**, aż będzie mniejsze od przyjętej wartości progowej
- **SLIC** – **podział metodą K-średnich** w przestrzeni wielowymiarowej

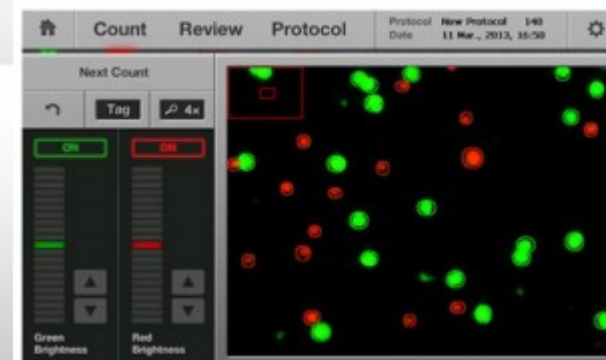
*Segmentacja – proces podziału obrazu na części / obszary lub tzw. “obiekty”, które są jednorodne pod względem wybranego kryterium. Może nim być poziom wartości, barwa, tekstura itp.*



# BLOB – Bright Object Detection

*Metody wyodrębniania obiektów wyróżniających się z obrazu, które mają jedną wspólną cechę, np. są dużo jaśniejsze od otoczenia.*




Najczęściej wykorzystywane do zliczania komórek lub drobnych organizmów w ruchu (urządzenia przepływowe mierzące w trybie rzeczywistym)



# BLOB – Bright Object Detection

Poznamy 3 podejścia:

- Laplacian of Gaussian LoG– najpierw obraz przetwarza się filtrem Gauss'a, a następnie Laplace'a przy znormalizowanej skali obiektów.
- *Uzyskuje się podwyższone wartości w miejscach obiektów ciemnych, a ujemne jasnych o promieniu  $r = \frac{d}{2}$ , gdzie  $d$  – wymiar obrazu,  $t$  – skala*
- Difference of Gaussians DoG– Laplasjan wyliczany jest dla różnicy dwóch obrazów przetworzonych filtrem Gauss'a o odmienej wielkości okna
- Determinant of the Hessian DoH – analiza lokalnych maximów po zastosowaniu operatora Monge–Ampère'a [Bay i in., 2008].



# Dla ciekawych

- Van der Walt et al. (2014), scikit-image: image processing in Python. PeerJ 2:e453, doi: 10.7717/peerj.453
- Hall-Beyer M., 2017. *GLCM texture: A tutorial v.3.0*. Arts Research & Publications, University of Calgary, doi: 10.11575/PRISM/33280
- Felzenszwalb P.F., Huttenlocher D.P., 2004. *Efficient Graph-Based Image Segmentation*. International Journal of Computer Vision, vol. 59(2), pp. 167–181, doi: 10.1023/B:VISI.00000022288.19776.77
- Zhang M., Gunturk B.K., 2008. *Multiresolution Bilateral Filtering for Image Denoising*. IEEE Trans Image Process, 17(12), pp. 2324–2333. doi:10.1109/TIP.2008.2006658
- Vedaldi A., Soatto S., 2008. *Quick shift and kernel methods for mode seeking*. European Conference on Computer Vision, doi: 10.1007/978-3-540-88693-8\_52
- Bay H., Ess A., Tuytelaars T., Gool L.V., 2008. *Speeded-Up Robust Features (SURF)*. Computer Vision and Image Understanding, vol. 110(3), pp. 346-359